

UMA - las, turniej

Dokumentacja końcowa

Michał Suski 331439, Kamil Marszałek 331401

1 Treść zadania

Zmodyfikowany las losowy w zadaniu klasyfikacji. Podczas budowy każdego z drzew testy (z pełnego zbioru testów) wybieramy za pomocą turnieju: <https://staff.elka.pw.edu.pl/~rbiedrzy/UMA/turniejRuletka.pdf>, czyli wybieramy losowo 2 testy, liczymy ich jakość, stosujemy ten z wyższą jakością. Do wstępnych testów polecam zbiór danych z zadaniem klasyfikacji grzybów: <https://archive.ics.uci.edu/dataset/73/mushroom>, na którym powinno dać się uzyskać wyniki w okolicy 100%. Do dalszych testów należy znaleźć i pobrać inne zbiory danych (na wskazanej stronie lub w Kaggle). Przed rozpoczęciem realizacji projektu proszę zapoznać się z zawartością: <https://staff.elka.pw.edu.pl/~rbiedrzy/UMA/index.html>.

2 Interpretacja i opis algorytmu

Projekt ma na celu sprawdzenie, czy wybór testów (podziałów węzłów) za pomocą prostego turnieju dwuelementowego poprawi własności klasycznego lasu losowego, w szczególności:

- zmniejszy skłonność pojedynczych drzew do przeuczenia,
- zwiększy *różnorodność* drzew w lesie (mniejsza korelacja pomiędzy drzewami),
- nie pogorszy istotnie jakości klasyfikacji w porównaniu z klasycznym wyborem najlepszego testu.

Funkcja wyboru testu (zachłannie lub turniejowo) oraz sposób oceny jego jakości będą parametrami modelu budującego las. Ułatwi to porównanie ich wpływu na skuteczność algorytmu.

- Zaimplementowane zostaną dwa typy drzew: podstawowe **ID3** oraz **CART**, dla lepszej obsługi atrybutów ciągłych.
- Dla drzew **CART** zostanie zaimplementowana osobna funkcja oceny jakości podziału (indeks Giniego) oraz sposób kodowania atrybutów kategoriycznych **one-hot encoding**.

2.1 Miary jakości testu

Test (podział) węzła S dzieli zgromadzone w nim przykłady na dwa (dla CART) lub więcej (dla ID3) podzbiorów. Jakość testu określamy na podstawie *nieczystości* węzła przed i po podziale. Dla węzła z podzbiorem S definiujemy udział klasy k :

$$p_k(S) = \frac{1}{|S|} |\{(x_i, y_i) \in S : y_i = k\}|$$

Przykładowe miary nieczystości:

- **Entropia:**

$$H(S) = - \sum_{k=1}^K p_k(S) \log_2 p_k(S)$$

- **Indeks Giniego:**

$$G(S) = 1 - \sum_{k=1}^K p_k(S)^2$$

Niech test t dzieli bazowy węzeł S na podzbiory $S_1, \dots, S_m$. Wtedy:

- **Information Gain:**

$$IG(t, S) = H(S) - \sum_{j=1}^m \frac{|S_j|}{|S|} H(S_j)$$

- **Gini Gain:**

$$GG(t, S) = G(S) - \sum_{j=1}^m \frac{|S_j|}{|S|} G(S_j)$$

W dalszej części projektu planujemy użyć:

- dla drzew ID3: domyślnie **Information Gain** oraz opcjonalnie **Gain Ratio**,
- dla drzew CART: **Gini Gain**.

3 Zbiory danych

1. Klasyfikacja grzybów

Źródło: <https://archive.ics.uci.edu/dataset/73/mushroom>

Typ zadania: klasyfikacja binarna (grzyb jadalny / trujący)

Liczba przykładów: 8124

Jadalne: 4208

Trujące: 3916

Liczba atrybutów: 22

Typ atrybutów: wszystkie dyskretne

Uwagi: zbiór prosty, klasy zbalansowane, przewidywana dokładność bliska 100%

2. Zaległości płatnicze klientów kart kredytowych

Źródło: <https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>

Typ zadania: klasyfikacja binarna (czy klient będzie zalegał z płatnością w przyszłym miesiącu?)

Liczba przykładów: 30000

Brak zaległości: 23364

Zaległość: 6636

Liczba atrybutów: 23

Typ atrybutów: ciągłe i dyskretne (liczbowe)

Uwagi: Klasy są niezbalansowane. Występuje duża liczba atrybutów ciągłych, co czyni go idealnym do testowania wydajności progów w algorytmie CART. Nie spodziewamy się dokładności 100%.

3. Skuteczność marketingu banku

Źródło: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

Typ zadania: klasyfikacja binarna (czy klient założy lokatę?)

Liczba przykładów: 45211

Nie założy lokaty: 39922

Założy lokatę: 5289

Liczba atrybutów: 16

Typ atrybutów: dyskretne i ciągłe

Uwagi: Klasy są niezbilansowane – trzeba zadbać, aby nie wpłynęło to na algorytm. Atrybuty ciągłe obsługiwane progiem (CART). Zbiór powinien dobrze pokazywać różnice przy testowaniu różnych funkcji oceny jakości testu. Nie spodziewamy się dokładności 100%.

4. Nawrót raka piersi (Breast Cancer)

Źródło: <https://archive.ics.uci.edu/dataset/14/breast+cancer>

Typ zadania: klasyfikacja binarna (czy nastąpi nawrót choroby?)

Liczba przykładów: 286

Brak nawrotu: 201

Nawrót: 85

Liczba atrybutów: 9

Typ atrybutów: dyskretne

Uwagi: Zbiór posiada niewiele przykładów, co pozwoli sprawdzić tendencje do przeuczenia. Występują nieliczne braki danych, które wymagają obsłużenia przed procesem uczenia. Przykłady nie są trywialne, przez co spodziewamy się dokładności poniżej 100%.

Aby zastosować zbiory **2** oraz **3** do drzew ID3 konieczne byłoby zdyskretyzowanie atrybutów ciągłych. Wprowadzałoby to jednak problemy z reprezentatywnością danych (na przykład mogłoby wprowadzić dodatkowe, pierwotnie nieistniejące zależności), dlatego zbiory te zostaną **pominięte** w procesie badania algorytmu ID3.

3.1 Metody podziału danych na zbiory trenujący i testowy

Bazową proporcją dla zbiorów trenującego / testowego będzie 70% / 30% – ten podział będzie **stratyfikowany** względem klas, aby zachować ich oryginalne proporcje. Do budowy pojedynczego drzewa wylosowana zostanie próbka danych ze zbioru trenującego.

4 Wybór technologii

Projekt został zaimplementowany w języku **Python** z wykorzystaniem bibliotek **NumPy** oraz **pandas**, które posłużą odpowiednio do obliczeń numerycznych i przetwarzania danych. W celu oceny jakości proponowanego rozwiązania oraz porównania jego skuteczności, jako punkt odniesienia zostanie wykorzystany klasyczny las losowy z pakietu **scikit-learn**.

5 Metodyka eksperymentalna

Przebieg pojedynczego uruchomienia badania:

- Podział zbioru danych na trenujący (70%) i testowy (30%) w sposób stratyfikowany.
- Budowa lasu na zbiorze trenującym zgodnie z ustalonymi parametrami.
- Użycie lasu do predykcji na zbiorze testowym oraz zebranie wyników.

Z uwagi na użycie w badanych modelach generatorów liczb pseudolosowych, przedstawiane w tym dokumencie wyniki będą zagregowane z **25 niezależnych uruchomień** takiego samego eksperymentu.

- Aby wyniki badań były powtarzalne, w skład parametrów eksperymentu wchodzi ziarno generatora liczb pseudolosowych.
- Przy każdej iteracji badania według tego ziarna dokonywany jest podział zbioru danych na zbiory trenujący i testowy oraz w sposób deterministyczny generowane są ziarna cząstkowe służące do budowy pojedynczych drzew.

W celu usprawnienia wykonywania badań zdefiniowany został system, który pobiera parametry eksperymentu z plików *.csv*, wykonuje zleczone badania i zapisuje wyniki do późniejszej analizy. Jako parametr podawane jest bazowe ziarno, które następnie w każdej iteracji jest inkrementowane, co zapewnia powtarzalność pomiarów.

Drzewa ID3 zostaną przetestowane na zbiorach **1** i **4**, natomiast drzewa CART na **wszystkich czterech** zbiorach. Drzewo z biblioteki *scikit-learn* jest typu CART, dlatego w porównaniu zostanie uwzględnione również na **wszystkich czterech** zbiorach.

6 Miary jakości eksperymentów

Dla każdego eksperymentu będziemy raportować:

6.1 Miary podstawowe

- Średnia arytmetyczna (uzyskanej dokładności)
- Najlepszy wynik
- Najgorszy wynik
- Średni czas budowy lasu
- Odchylenie standardowe:

Dla serii n powtórzeń tego samego eksperymentu, odchylenie standardowe z próby definiujemy jako:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

gdzie:

- n – liczba powtórzeń eksperymentu,
- x_i – wynik (dokładność) uzyskany w i -tym powtórzeniu,
- $\bar{x}$ – średnia arytmetyczna wyników ze wszystkich powtórzeń: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

Te miary przedstawiają ogólny obraz wyników modelu.

6.2 Macierz pomyłek i dokładność

Dla binarnej klasyfikacji definiujemy macierz pomyłek:

	Predykcja: pozytywna	Predykcja: negatywna
Rzeczywista: pozytywna	TP	FN
Rzeczywista: negatywna	FP	TN

gdzie:

- TP – (ang. true positives) poprawnie rozpoznane przykłady pozytywne,
- TN – (true negatives) poprawnie rozpoznane przykłady negatywne,
- FP – (false positives) negatywne zaklasyfikowane jako pozytywne,
- FN – (false negatives) pozytywne zaklasyfikowane jako negatywne.

Dokładność (accuracy) zdefiniowana jest jako:

$$\text{Dokładność} = \frac{TP + TN}{TP + TN + FP + FN}$$

6.3 Precyzja, czułość i F1-score

Dla klasy pozytywnej definiujemy:

$$\text{Precyzja} = \frac{TP}{TP + FP}, \quad \text{Czułość} = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \cdot \text{Precyzja} \cdot \text{Czułość}}{\text{Precyzja} + \text{Czułość}}$$

Miary te są szczególnie istotne przy niezbalansowanych zbiorach (np. Adult, Bank Marketing), gdzie sama dokładność może być myląca.

7 Wpływ hiperparametrów na jakość modelu

Jako domyślne hiperparametry zostały przyjęte:

Tablica 1: Domyślne hiperparametry dla modeli leśnych

Parametr	Las ID3	Las CART
Liczba drzew	100	
Współczynnik próbkowania (sample ratio)	100%	
Maksymalna głębokość drzewa	Bez limitu	
Rozmiar turnieju wyboru cech	2	
Minimalna liczba próbek do podziału	nie dotyczy	2
Funkcja oceny jakości testu (Gain)	Information Gain	Gini Gain

W jednym badaniu zmieniał się dokładnie **jeden** sprawdzany hiperparametr.


Dla każdego badania przeanalizowane zostały dokładność, czułość, precyzja, wynik F1 oraz czas trenowania lasu. W celu utrzymania przejrzystości dokumentu wyniki zostaną zaprezentowane w postaci zaagregowanych wykresów. Wykresy nie są w stanie przedstawić małych różnic w wynikach, jednak ze względu na stochastyczny charakter badanych algorytmów, różnice te mogą być uznane za szum statystyczny – z tego powodu dodatkowe tabele nie zostały zawarte w dokumencie.

7.1 Liczba drzew w lesie

7.1.1 ID3

- Zbiór 73 - Grzyby


Algorytm osiąga stabilne 100% dokładności już przy 5 drzewach i utrzymuje ten wynik wraz ze zwiększaniem ich liczby.



Rysunek 1: Wpływ liczby drzew na dokładność modelu ID3 dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi

Przy trudniejszym zbiorze danych optymalne wyniki osiągane są przy liczbie drzew równej 100. Powyżej tej wartości poprawa jest na tyle nieznaczna, że można ją uznać za statystyczny szum.




Rysunek 2: Wpływ liczby drzew na dokładność modelu ID3 dla zbioru 14 - Nawrót raka piersi.

7.1.2 CART

Sprawdzone wartości zostały ograniczone do maksymalnie 200 drzew ze względu na długi czas wykonywania badania.

- Zbiór 73 - Grzyby


Drzewa CART radzą sobie gorzej od ID3 - 100% dokładności osiągają dopiero przy 50 drzewach. Wynika to z odmiennego sposobu kodowania atrybutów kategorycznych (one-hot encoding), które prowadzi do zwiększenia wymiarowości danych i wpływa na efektywność modelu. Powyżej 50 drzew miary czułości, precyzji i F1-score ulegają nieznacznej poprawie wraz ze wzrostem liczby drzew – model jest w stanie lepiej radzić sobie z trudniejszymi przykładami.



Rysunek 3: Wpływ liczby drzew na dokładność modelu CART dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi


Liczba drzew nie wpływa znacząco na dokładność, jednak do liczby 50 drzew obserwujemy wyraźną poprawę miary precyzji. Wskazuje to na redukcję wariancji modelu i skuteczniejszą eliminację błędów fałszywie pozytywnych (False Positives) poprzez mechanizm głosowania większościowego.



Rysunek 4: Wpływ liczby drzew na dokładność modelu CART dla zbioru 14 - Nawrót raka piersi.

- Zbiór 222 - Skuteczność marketingu bankowego


Obserwacje oraz wnioski są podobne jak dla zbioru 14. Liczba drzew powyżej 50 nie wpływa znacząco na dokładność, jednak do tej wartości widoczna jest poprawa precyzji modelu. Warto zauważyć również bardzo niskie poziomy czułości oraz F1-score, które wskazują na trudność zbioru danych. Algorytm ma problem z wykryciem klasy pozytywnej i w znacznej liczbie przypadków działa podobnie jak klasyfikator naiwny zawsze przewidujący klasę negatywną.



Rysunek 5: Wpływ liczby drzew na dokładność modelu CART dla zbioru 222 - Skuteczność marketingu bankowego.

- Zbiór 350 - Zaległości płatnicze klientów kart kredytowych

Na tym zbiorze wzrost liczby drzew wpływa nie tylko na poprawę precyzji modelu, ale też czułość oraz F1-score. Oznacza to, że zwiększenie liczby drzew pozwala na redukcję zarówno błędów fałszywie pozytywnych (False Positives), jak i fałszywie negatywnych (False Negatives). Wpływ na dokładność jest jednak niewielki.



Rysunek 6: Wpływ liczby drzew na dokładność modelu CART dla zbioru 350 - Zaległości płatnicze klientów kart kredytowych.

7.1.3 Wnioski ogólne

- Uzasadnionym jest stosowanie lasu losowego o liczbie drzew równej co najmniej 50, gdyż pozwala to na stabilizację wyników i redukcję wariancji modelu.
- W porównywaniu modeli zostanie utrzymana liczba drzew w lesie równa 100.


7.2 Współczynnik próbkowania zbioru trenującego

Współczynnik próbkowania określa, jak dużą część zbioru trenującego wykorzystujemy do budowy pojedynczego drzewa w lesie. Jego mniejsze wartości zwiększają różnorodność drzew, co może prowadzić do redukcji zjawiska przeuczenia. Z drugiej strony przy małych zbiorach danych może prowadzić do niedouczenia poszczególnych drzew.

7.2.1 ID3

- Zbiór 73 - Grzyby


Wyniki są stabilne i osiągają 100% dokładności od współczynnika równego 40%. Odchylenia dla wartości 20% wynikają z faktu, iż przy tak małej próbce rozkład klas w zbiorze trenującym może nie być reprezentatywny.



Rysunek 7: Wpływ współczynnika próbkowania na dokładność modelu ID3 dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi

Ten zbiór danych posiada niewiele przykładów, co sprawia, że zbyt mały współczynnik próbkowania prowadzi do niedouczenia drzew. Optymalne wyniki osiągane są przy współczynniku równym 100%.




Rysunek 8: Wpływ współczynnika próbkowania na dokładność modelu ID3 dla zbioru 14 - Nawrót raka piersi.

7.2.2 CART

- Zbiór 73 - Grzyby


Na trywialnym zbiorze grzybów optymalne okazuje się ustawienie współczynnika próbkowania w okolicy 70%. Spadek dokładności przy wartości 100% wskazuje na wystąpienie zjawiska przecuczania w pojedynczych drzewach, które skumulowane wpływa na pogorszenie wyników lasu.



Rysunek 9: Wpływ współczynnika próbkowania na dokładność modelu CART dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi


Zbiór ten w przeciwieństwie do grzybów jest trudniejszy, przez co większy współczynnik próbkowania przekłada się na lepsze wyniki. 100% okazuje się optymalną wartością, gdyż dla mniejszych wartości obserwujemy niedouczenie drzew.



Rysunek 10: Wpływ współczynnika próbkowania na dokładność modelu CART dla zbioru 14 - Nawrót raka piersi.

- Zbiór 222 - Skuteczność marketingu bankowego


Na dużych zbiorach z niezbalansowanymi klasami sterowanie współczynnikiem próbkowania nie wpływa znacząco na uzyskiwane wyniki.



Rysunek 11: Wpływ współczynnika próbkowania na dokładność modelu CART dla zbioru 222 - Skuteczność marketingu bankowego.

- Zbiór 350 - Zaległości płatnicze klientów kart kredytowych

Na dużych zbiorach z niebalansowanymi klasami sterowanie współczynnikiem próbkowania nie wpływa znacząco na uzyskiwane wyniki.



Rysunek 12: Wpływ współczynnika próbkowania na dokładność modelu CART dla zbioru 350 - Zaległości płatnicze klientów kart kredytowych.

7.2.3 Wnioski ogólne


- Stosowanie współczynnika próbkowania poniżej 100% jest uzasadnione jedynie w przypadku, gdy zbiór danych jest mały oraz nietrywialny. Wtedy przyjęcie wartości w okolicy 70% pozwala na redukcję zjawiska przeuczenia.
- W pozostałych przypadkach stosowanie współczynnika próbkowania równego 100% pozwala na uzyskanie najlepszych wyników.

7.3 Maksymalna głębokość drzew

7.3.1 ID3

- Zbiór 73 - Grzyby


Nawet przy minimalnej głębokości drzewa model osiąga 100% dokładności, co wskazuje na trywialność zbioru.



Rysunek 13: Wpływ maksymalnej głębokości na dokładność modelu ID3 dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi

Maksymalna głębokość drzewa nie wpływa na wyniki modelu.




Rysunek 14: Wpływ maksymalnej głębokości na dokładność modelu ID3 dla zbioru 14 - Nawrót raka piersi.

7.3.2 CART

- Zbiór 73 - Grzyby


Obserwujemy poprawę wyników modelu wraz ze wzrostem maksymalnej głębokości drzew. Wynika to z faktu, iż atrybuty kategoryczne zostały zakodowane za pomocą one-hot encoding, co zwiększa wymiarowość danych i wymaga głębszych drzew do skutecznej separacji klas.



Rysunek 15: Wpływ maksymalnej głębokości na dokładność modelu CART dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi


Wzrost głębokości początkowo poprawia wyniki modelu, a powyżej głębokości równej 5 obserwujemy brak dalszej poprawy.



Rysunek 16: Wpływ maksymalnej głębokości na dokładność modelu CART dla zbioru 14 - Nawrót raka piersi.

- Zbiór 222 - Skuteczność marketingu bankowego


Przy głębokości drzew mniejszej niż 10 model zachowuje się całkowicie jak klasyfikator naiwny zawsze przewidyujący klasę negatywną. Trudniejsze zbiory wymagają głębszych drzew do skutecznej separacji klas.



Rysunek 17: Wpływ maksymalnej głębokości na dokładność modelu CART dla zbioru 222 - Skuteczność marketingu bankowego.

- Zbiór 350 - Zaległości płatnicze klientów kart kredytowych

Podobnie jak w pozostałych przypadkach, wzrost maksymalnej głębokości drzew przekłada się na poprawę wyników modelu.



Rysunek 18: Wpływ maksymalnej głębokości na dokładność modelu CART dla zbioru 350 - Zaległości płatnicze klientów kart kredytowych.

7.3.3 Wnioski ogólne


- Wyniki wskazują, że stosowanie ograniczenia maksymalnej głębokości drzew nie jest uzasadnione na badanych zbiorach danych.
- W porównywaniu modeli zostanie utrzymany brak ograniczenia maksymalnej głębokości drzew.

7.4 Rozmiar turnieju

7.4.1 ID3

- Zbiór 73 - Grzyby


Zbiór jest na tyle trywialny, że nawet losowy wybór cech podziału węzła (turniej o rozmiarze 1) pozwala na osiągnięcie 100% dokładności.



Rysunek 19: Wpływ rozmiaru turnieju na dokładność modelu ID3 dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi

Obserwujemy spadek dokładności wraz ze wzrostem liczebności turnieju. Przykłady z tego zbioru posiadają niewiele atrybutów, przez co ustawienie wielkości turnieju na 10 prowadzi do bardzo małej różnorodności drzew w lesie i wzrostu wariancji modelu oraz przeuczenia.




Rysunek 20: Wpływ rozmiaru turnieju na dokładność modelu ID3 dla zbioru 14 - Nawrót raka piersi.

7.4.2 CART

- Zbiór 73 - Grzyby


W przypadku radzenia sobie ze zwiększoną liczbą atrybutów (one-hot encoding) większy rozmiar turnieju pozwala na wybór bardziej reprezentatywnych cech podziału, co przekłada się na lepsze wyniki modelu. Zwiększenie rozmiaru turnieju pozwala uniknąć zjawiska niedouczenia drzew.



Rysunek 21: Wpływ rozmiaru turnieju na dokładność modelu CART dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi


Wzrost rozmiaru turnieju nie wpływa na dokładność modelu, jednak obserwujemy poprawę czułości oraz F1-score, przy jednoczesnym spadku precyzji. Oznacza to, że model przesuwą swój punkt pracy w stronę maksymalizacji wykrywalności. Zwiększenie rozmiaru turnieju faworyzuje te podziały w drzewach, które skuteczniej separują klasę mniejszościową (nawrót), nawet za cenę częstszego mylenia się na klasie większościowej (zdrowi).



Rysunek 22: Wpływ rozmiaru turnieju na dokładność modelu CART dla zbioru 14 - Nawrót raka piersi.

- Zbiór 222 - Skuteczność marketingu bankowego


Obserwacje są podobne jak dla zbioru 14. Dodatkowo warto zauważyć, że wraz ze wzrostem rozmiaru turnieju znacząco rośnie czas trenowania lasu.



Rysunek 23: Wpływ rozmiaru turnieju na dokładność modelu CART dla zbioru 222 - Skuteczność marketingu bankowego.

- Zbiór 350 - Zaległości płatnicze klientów kart kredytowych

Na tym zbiorze wzrost rozmiaru turnieju nie wpływa znacząco na wyniki modelu.



Rysunek 24: Wpływ rozmiaru turnieju na dokładność modelu CART dla zbioru 350 - Zaległości płatnicze klientów kart kredytowych.

7.4.3 Wnioski ogólne


- Wzrost liczebności turnieju zazwyczaj nie wpływa znacząco na dokładność modelu.
- Prowadzi jednak do zwiększenia zdolności wykrywania przez model klas mniejszościowych - zwiększenia czułości kosztem precyzji.
- Cecha ta może być użyteczna w przypadku zbiorów z niezbalansowanymi klasami w szczególności w pewnych rzeczywistych zastosowaniach, na przykład w medycynie, gdzie wykrycie choroby (klasa mniejszościowa) jest ważniejsze niż uniknięcie fałszywych alarmów.
- W porównaniu algorytmów zostanie przyjęty rozmiar turnieju równy 3 jako kompromis pomiędzy czułością a precyzją.

7.5 Funkcja jakości testu (tylko ID3)

Dla drzew CART została zaimplementowana tylko jedna taka funkcja, dlatego badanie nie zostało wykonane.

- Zbiór 73 - Grzyby


Zastosowana funkcja miary jakości nie ma żadnego wpływu na wyniki modelu na tym trywialnym zbiorze danych.



Rysunek 25: Wpływ funkcji jakości testu na dokładność modelu ID3 dla zbioru 73 - Grzyby.

- Zbiór 14 - Nawrót raka piersi

Delikatnie wyróżniła się funkcja **gain ratio**, dla której wszystkie miary są minimalnie większe. Różnica jest na tyle mała, że może być to uznane za szum statystyczny, jednak z uwagi na brak innych przesłanek zostanie ona wybrana jako domyślna dla drzew ID3 w porównaniu modeli.




Rysunek 26: Wpływ funkcji jakości testu na dokładność modelu ID3 dla zbioru 14 - Nawrót raka piersi.

8 Porównanie modeli

Przyjęte hiperparametry zostały skorygowane o wyniki z poprzedniego punktu badań - zmienił się jedynie rozmiar turnieju na 3. W porównaniu pominięty został trywialny zbiór grzybów. Drzewo ID3 było porównywane jedynie na zbiorze nawrotu raka piersi. Lasy ID3 oraz CART stanowią naszą własną implementację z wyborem atrybutów podziału na podstawie turnieju, natomiast las

SKLEARN to standardowy, niezmodyfikowany las losowy.

8.1 Zbiór 14 - Nawrót raka piersi



Rysunek 27: Porównanie modeli dla zbioru 14 - Nawrót raka piersi.

Tablica 2: **Dokładność** - Typ lasu (zbiór 14)

Typ lasu	Średnia	Std	Maks	Min
CART	0,734	0,021	0,793	0,701
ID3	0,732	0,026	0,770	0,667
SKLEARN	0,726	0,028	0,782	0,678

Tablica 3: **Precyzja** - Typ lasu (zbiór 14)

Typ lasu	Średnia	Std	Maks	Min
CART	0,691	0,132	1,000	0,500
ID3	0,595	0,081	0,727	0,412
SKLEARN	0,561	0,070	0,667	0,429

Tablica 4: **Czulość** - Typ lasu (zbiór 14)


Typ lasu	Średnia	Std	Maks	Min
CART	0,214	0,084	0,423	0,077
ID3	0,348	0,080	0,462	0,154
SKLEARN	0,363	0,108	0,577	0,115

Tablica 5: **F1** - Typ lasu (zbiór 14)

Typ lasu	Średnia	Std	Maks	Min
CART	0,316	0,099	0,550	0,138
ID3	0,432	0,075	0,545	0,250
SKLEARN	0,434	0,096	0,612	0,188

CART oraz ID3 nieznacznie przewyższają implementację z biblioteki SKLEARN pod względem dokładności. Lepszymi właściwościami charakteryzuje się tutaj las ID3, który stanowi lepszy balans pomiędzy precyzją a czułością, co przekłada się na wyższe wartości F1-score. Na tym zbiorze skorzystanie z wyboru atrybutów podziału węzła na podstawie turnieju okazało się korzystne.

8.2 Zbiór 222 - Skuteczność marketingu bankowego



Rysunek 28: Porównanie modeli dla zbioru 222 - Skuteczność marketingu bankowego.

Tablica 6: **Dokładność** - Typ lasu (zbiór 222)

Typ lasu	Średnia	Std	Maks	Min
CART	0,897	0,001	0,899	0,894
SKLEARN	0,905	0,002	0,909	0,901

Tablica 7: **Precyzja** - Typ lasu (zbiór 222)

Typ lasu	Średnia	Std	Maks	Min
CART	0,765	0,022	0,805	0,704
SKLEARN	0,666	0,013	0,689	0,634

Tablica 8: **Czułość** - Typ lasu (zbiór 222)


Typ lasu	Średnia	Std	Maks	Min
CART	0,169	0,009	0,190	0,153
SKLEARN	0,383	0,013	0,407	0,358

Tablica 9: **F1** - Typ lasu (zbiór 222)

Typ lasu	Średnia	Std	Maks	Min
CART	0,276	0,012	0,305	0,255
SKLEARN	0,486	0,012	0,511	0,458

Implementacja lasu CART uzyskała nieco niższą dokładność niż las z biblioteki SKLEARN oraz cechuje się gorszymi właściwościami ogólnymi. Zastosowanie modyfikacji lasu nie jest w tym przypadku uzasadnione.

8.3 Zbiór 350 - Zaległości płatnicze klientów kart kredytowych



Rysunek 29: Porównanie modeli dla zbioru 350 - Zaległości płatnicze klientów kart kredytowych.

Tablica 10: **Dokładność** - Typ lasu (zbiór 350)

Typ lasu	Średnia	Std	Maks	Min
CART	0,818	0,002	0,822	0,816
SKLEARN	0,816	0,002	0,821	0,812

Tablica 11: **Precyzja** - Typ lasu (zbiór 350)

Typ lasu	Średnia	Std	Maks	Min
CART	0,666	0,008	0,680	0,650
SKLEARN	0,648	0,012	0,671	0,623

Tablica 12: **Czułość** - Typ lasu (zbiór 350)

Typ lasu	Średnia	Std	Maks	Min
CART	0,361	0,008	0,377	0,346
SKLEARN	0,373	0,008	0,388	0,353

Tablica 13: **F1** - Typ lasu (zbiór 350)

Typ lasu	Średnia	Std	Maks	Min
CART	0,468	0,007	0,483	0,456
SKLEARN	0,473	0,007	0,487	0,459

Wariant bazowy oraz zmodyfikowany uzyskały bardzo zbliżone do siebie wyniki. Nie da się jednoznacznie wskazać lepszego modelu na tym zbiorze danych.

9 Wnioski

Przeprowadzona analiza nie wykazała jednoznacznie, czy modyfikacje lasu losowego w postaci wyboru atrybutów podziału na podstawie turnieju przekładają się na poprawę jakości modelu. W przypadku niektórych zbiorów danych mogą one pozwalać na uzyskanie lepszych wyników przez zwiększenie różnorodności drzew w lesie, ale również dla danych o innej charakterystyce mogą nie prowadzić do żadnej poprawy, a nawet powodować pogorszenie zachowania modelu. Potencjalne zastosowanie tej modyfikacji w praktyce wymagałoby przeprowadzenia analizy na specyficznym zbiorze danych przypisanym do danego problemu, aby ocenić jej skuteczność w konkretnym przypadku.